Instituto Tecnológico de Buenos Aires

16.63 Procesamiento de Señales e Imágenes Biomédicas — 2026 Q2

Informe TPI
Grupo 3

Segmentación y extracción de características morfológicas, de color y de textura en imágenes dermatoscópicas para el análisis de lesiones cutáneas

Integrantes

Lola Cendoya — Legajo 65687
Camila Sanchez — Legajo 62781
Luana Tobal — Legajo 65219

Docentes

Roberto Sebastián Tomás, Lucila Capurro, Francisco Tassara, Victoria Reppucci

Repositorio:
`https://github.com/gintonic06/PSIB2026Q2-TPI-Grupo03-Cendoya-Sanchez-Tobal`

5 de noviembre de 2026

1. Introducción

1.1. Marco teórico

Las lesiones pigmentadas de la piel son muy frecuentes y, en su gran mayoría, benignas. Este trabajo estudia tres tipos, que son los que incluye el conjunto de datos utilizado.

El melanoma es un tumor maligno que se origina en los melanocitos, las células de la piel que producen el pigmento melanina. Es el tipo de cáncer de piel con mayor mortalidad, porque puede diseminarse a otros órganos; si se detecta en una etapa temprana, en cambio, suele tratarse con una cirugía simple. Por eso, la detección temprana es fundamental.

El nevus, conocido comúnmente como lunar, es una proliferación benigna de melanocitos. Como comparte su origen con el melanoma, ambas lesiones pueden presentar un aspecto parecido, y distinguirlas es el principal desafío del diagnóstico.

La queratosis seborreica es una lesión benigna que no se origina en los melanocitos, sino en los queratinocitos de la epidermis. Es muy frecuente en adultos mayores y, aunque no tiene relación con el melanoma, puede presentar un aspecto similar, por lo que ambas lesiones se confunden en la práctica clínica [1].

Para examinar estas lesiones se utiliza la dermatoscopía, una técnica no invasiva que ilumina y amplía la piel y elimina el reflejo de su superficie. Así permite observar estructuras pigmentadas que no son visibles a simple vista, y se recomienda para examinar las lesiones sospechosas [1].

Para estandarizar la evaluación dermatoscópica, Stolz et al. [2] propusieron la regla ABCD, que puntúa cuatro criterios: la asimetría de la lesión respecto de dos ejes perpendiculares (A, de 0 a 2 puntos), la irregularidad del borde (B, de 0 a 8 segmentos con un corte abrupto), la cantidad de colores presentes (C, de 1 a 6, entre blanco, rojo, marrón claro, marrón oscuro, azul grisáceo y negro) y las estructuras diferenciales, como retículos, puntos o glóbulos (D, de 1 a 5). Con ellos se calcula la puntuación dermatoscópica total:

$$\mathrm{TDS} = 1{,}3\,A + 0{,}1\,B + 0{,}5\,C + 0{,}5\,D \tag{1}$$

Una puntuación superior a 4,75 se considera sospechosa de melanoma. Estos criterios motivan las características que se miden en este trabajo: la asimetría y la forma del borde (criterios A y B), la variedad de colores (criterio C) y la textura, como aproximación a las estructuras diferenciales (criterio D).

1.2. Estado del arte

Los primeros sistemas de análisis automático de imágenes dermatoscópicas se basaron en métodos clásicos de procesamiento. En ellos, la imagen se preprocesa para reducir artefactos como pelos y reflejos, la lesión se segmenta y se extraen características inspiradas en la regla ABCD, como medidas de forma y asimetría, estadísticos de color y descriptores de textura, que luego se utilizan para clasificar la lesión [3]. Estos sistemas son interpretables, ya que cada característica tiene un significado clínico, pero su desempeño depende de la calidad de la segmentación y de las condiciones de adquisición de las imágenes.

El desafío ISIC 2017 [4], organizado por la International Skin Imaging Collaboration, proporcionó un conjunto público de imágenes con segmentaciones y diagnósticos de especialistas, que es el que se utiliza en este trabajo, y estableció un marco común para comparar métodos. Los mejores resultados se obtuvieron con redes neuronales profundas. En segmentación, la mejor propuesta, basada en redes totalmente convolucionales, alcanzó un índice de Jaccard medio de 0,765 [5]. En clasificación, el mejor AUC fue de 0,874 para detectar melanoma y de 0,965 para detectar queratosis seborreica [4]. Actualmente, las redes profundas constituyen el estado del arte, aunque requieren grandes conjuntos de imágenes etiquetadas y sus decisiones son más difíciles de interpretar que las de los métodos clásicos.

1.3. Objetivos

Objetivo general: desarrollar un algoritmo de procesamiento de imágenes dermatoscópicas que segmente automáticamente las lesiones cutáneas y obtenga características cuantitativas, para analizar

si estas difieren entre melanoma, nevus y queratosis seborreica.

Objetivos específicos:

- Caracterizar el conjunto de imágenes e identificar factores de adquisición que puedan afectar el análisis.
- Evaluar técnicas de preprocesamiento (suavizado, mejora de contraste, elección del canal de color y eliminación de pelos) según su efecto sobre la segmentación.
- Implementar y comparar cinco métodos de segmentación respecto de las máscaras de los especialistas.
- Extraer características de forma, color y textura, y analizar estadísticamente sus diferencias entre diagnósticos.
- Evaluar cómo influyen sobre las características la segmentación automática, el origen de las imágenes y la compresión.

El trabajo no busca clasificar las lesiones ni diagnosticarlas: no se construye un clasificador que asigne un diagnóstico a cada imagen, sino que se estudia si las características medidas difieren entre los grupos.

2. Materiales y métodos

La Figura 1 resume el algoritmo desarrollado. Cada etapa se describe en las secciones siguientes.

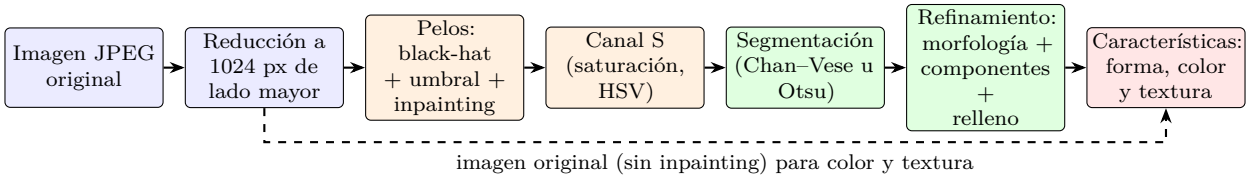


Figura 1: Algoritmo desarrollado. Las etapas en naranja corresponden al preprocesamiento, en verde a la segmentación y en rojo a la extracción de características. El color y la textura se miden sobre la imagen sin corrección, para no incorporar valores estimados por el inpainting.

2.1. Datos y herramientas

Se utilizó el conjunto de entrenamiento de ISIC 2017 [4], formado por 2000 imágenes JPEG (1372 nevus, 374 melanomas y 254 queratosis seborreicas). Cada imagen tiene su diagnóstico y una máscara de referencia de la lesión, realizada por especialistas. Se seleccionaron al azar una muestra de evaluación de 150 imágenes (50 por diagnóstico) y un conjunto de ajuste independiente de 30 imágenes, que se utilizó solo para elegir parámetros. Las máscaras de referencia se usaron únicamente para evaluar y para elegir parámetros, nunca dentro de la segmentación.

El código se implementó en Python 3.12, con las bibliotecas OpenCV, scikit-image, NumPy, SciPy y pandas, en el notebook `Pipeline_V2.ipynb`. El notebook contiene el código, las figuras y la interpretación de cada etapa; todas las figuras de este informe, salvo la Figura 1, son salidas del notebook. El README del repositorio describe la instalación (`requirements.txt`) y la ejecución, y el archivo `resultados/caracteristicas_lesiones.csv` contiene las características extraídas de cada lesión.

2.2. Caracterización de las imágenes

Se registraron el formato, las dimensiones, la cantidad de canales, la profundidad de bits y los histogramas RGB, HSV y en escala de grises de las imágenes. Todo el procesamiento posterior se realizó a una resolución de trabajo de 1024 píxeles de lado mayor, la más frecuente del conjunto, para que los parámetros expresados en píxeles tengan un efecto comparable en todas las imágenes.

Para elegir el canal de color sobre el que se segmenta, se midió en cada imagen y en cada canal la separación entre la lesión y el fondo:

$$\text{separación} = \frac{|\mu_{\text{lesión}} - \mu_{\text{fondo}}|}{\sigma_{\text{imagen}}} \tag{2}$$

donde $\mu_{\text{lesión}}$ y μ_{fondo} son las intensidades medias dentro y fuera de la máscara de referencia, y σ_{imagen} es el desvío estándar de toda la imagen. Valores mayores indican que la lesión se distingue mejor del fondo.

2.3. Preprocesamiento

2.3.1. Suavizado y mejora de contraste

Se compararon filtros de mediana y gaussianos con ventanas de 3×3 y 5×5, mediante el gradiente medio de Sobel, que mide cuánto se atenúan las variaciones locales, y la PSNR respecto de la imagen original. También se compararon la ecualización global del histograma y la ecualización adaptativa CLAHE (límite de contraste 2 y grilla de 8×8), mediante la separación lesión–fondo de la Ecuación (2).

2.3.2. Eliminación de pelos y reconstrucción

Los pelos se detectaron con la transformación black-hat (cierre de la imagen menos la imagen), que resalta las estructuras oscuras más finas que el elemento estructurante. La respuesta se umbralizó y se refinó con un cierre morfológico. Los píxeles marcados como pelo se reconstruyeron mediante inpainting, que estima su valor a partir de los píxeles vecinos. El tamaño del elemento estructurante (5, 9 o 13 píxeles) y el umbral (10 a 30) se eligieron con un barrido sobre el conjunto de ajuste, buscando el mayor Dice de la segmentación con Otsu.

2.4. Segmentación

Se compararon cinco métodos de segmentación, todos aplicados sobre el canal S (saturación) de la imagen corregida:

- Umbral global fijo: se utiliza el mismo umbral para todas las imágenes, elegido en el conjunto de ajuste.
- Otsu: el umbral se calcula automáticamente para cada imagen a partir de su histograma.
- Canny: se detectan los bordes de la imagen suavizada, con un umbral alto igual a un percentil de la magnitud del gradiente de cada imagen (elegido en el conjunto de ajuste) y un umbral bajo igual a la mitad; luego, los bordes se unen con un cierre y se rellenan las regiones encerradas.
- Crecimiento de regiones: a partir de una semilla ubicada en el punto más interior de la máscara de Otsu, se incorporan los píxeles vecinos cuya saturación difiere de la media de la región en menos de una tolerancia, proporcional al desvío de la imagen y elegida en el conjunto de ajuste.
- Chan–Vese: contorno activo inicializado con una elipse central, con 150 iteraciones y un suavizado de 2, aplicado a 512 píxeles de lado mayor.

A todas las máscaras se les aplicó el mismo refinamiento: un cierre de 9×9 y una apertura de 3×3; la selección de la componente conectada de mayor área, junto con las componentes cercanas (a menos del 3 % del lado menor de la imagen) que tengan al menos el 10 % de su área; y el relleno de los huecos.

Cada segmentación A se comparó con la máscara de referencia B mediante el coeficiente de Dice y el índice de Jaccard, que valen 1 cuando ambas máscaras coinciden y 0 cuando no se superponen:

$$\text{Dice} = \frac{2\,|A \cap B|}{|A| + |B|} \qquad \text{Jaccard} = \frac{|A \cap B|}{|A \cup B|} \tag{3}$$

2.5. Extracción de características

Para cada lesión se calcularon 25 características, que se resumen en la Tabla 1. Se midieron dos veces: con la máscara de referencia, para estudiar las diferencias entre diagnósticos, y con la máscara automática de Chan–Vese, para evaluar el efecto de la segmentación. Como no se conoce la escala física de las imágenes (cuántos milímetros representa un píxel), se priorizaron características adimensionales, que no dependen del tamaño de la imagen. El color y la textura se midieron sobre la imagen original, sin inpainting.

Tabla 1: Características extraídas de cada lesión, agrupadas según el criterio de la regla ABCD con el que se relacionan.

Característica	Qué mide
Forma (criterios A y B), 8 características	
Área relativa	Porcentaje de la imagen que ocupa la lesión. Depende del encuadre, por lo que no indica el tamaño real.
Circularidad	Cuánto se parece el contorno a un círculo (Ecuación 4).
Solidez	Área de la lesión dividida por el área de su envolvente convexa; disminuye si el borde tiene entrantes.
Convexidad	Perímetro de la envolvente convexa dividido por el perímetro de la lesión; disminuye si el borde es dentado.
Relación de ejes	Eje menor dividido por eje mayor de la elipse equivalente; cercana a 0 en lesiones alargadas.
Asimetría (eje mayor, eje menor y media)	Fracción de la lesión que no coincide con su reflejo respecto de cada eje principal (Ecuación 5).
Color (criterio C), 9 características	
Media y desvío de R, G y B	Color promedio de la lesión y su variabilidad en cada canal.
Media de S	Saturación promedio de la lesión.
Heterogeneidad de color	Variedad de colores de la lesión en el espacio CIELAB (Ecuación 6).
Contraste lesión–piel	Diferencia relativa de brillo entre la lesión y un anillo de piel que la rodea (Ecuación 7).
Textura (aproximación al criterio D), 8 características	
Contraste, homogeneidad, energía y correlación de la GLCM, a 1 y a 3 píxeles	Cómo varía la intensidad entre píxeles vecinos dentro de la lesión. Se calculan solo con pares de píxeles de la lesión, con 32 niveles de gris, y se promedian en cuatro orientaciones.

La circularidad se calcula a partir del área A y el perímetro P de la lesión, y vale 1 para un círculo perfecto:

$$\text{circularidad} = \frac{4\pi A}{P^2} \tag{4}$$

Para la asimetría, la lesión L se alinea con sus ejes principales y se refleja respecto de cada uno, obteniendo L'. La asimetría es el área que no se superpone entre ambas, relativa al área de la lesión; vale 0 para una lesión perfectamente simétrica:

$$\text{asimetría} = \frac{|L \setminus L'| + |L' \setminus L|}{2\,|L|} \tag{5}$$

La heterogeneidad de color se mide en el espacio CIELAB, en el que cada color se describe por su luminosidad (L^*) y dos coordenadas de color (a^*, de verde a rojo, y b^*, de azul a amarillo). Este espacio es aproximadamente uniforme para la percepción humana: la distancia entre dos colores se parece a la diferencia que percibe el ojo. Se calcula a partir de los desvíos dentro de la lesión:

$$\text{heterogeneidad} = \sqrt{\sigma_{L^*}^2 + \sigma_{a^*}^2 + \sigma_{b^*}^2} \tag{6}$$

El contraste lesión–piel compara el brillo medio (canal V de HSV) de la lesión con el de un anillo de piel que la rodea, de ancho igual al 3 % del lado mayor de la imagen:

$$\text{contraste} = \frac{\bar{V}_{\text{piel}} - \bar{V}_{\text{lesión}}}{\bar{V}_{\text{piel}}} \tag{7}$$

2.6. Análisis de compresión

Como las imágenes médicas se almacenan y transmiten comprimidas, se evaluó el efecto de la compresión sobre el algoritmo. Primero, se estimó la calidad JPEG con la que se guardó cada imagen original, a partir de la tabla de cuantificación de su encabezado. Luego, cada imagen de la muestra, a la resolución de trabajo, se comprimió y descomprimió en PNG, que es sin pérdida, y en JPEG con calidades de 95, 75, 50, 25 y 10. Para cada variante se midieron la tasa de compresión,

$$\text{tasa} = \frac{\text{tamaño de la imagen sin comprimir}}{\text{tamaño del archivo comprimido}} \tag{8}$$

la calidad de la imagen reconstruida respecto de la original (PSNR y SSIM), el Dice de la segmentación con Otsu y el cambio relativo de las características de color y textura. Se utilizó Otsu en lugar de Chan–Vese porque ambos tienen un desempeño similar y Otsu es mucho más rápido, lo que permite repetir el proceso para las seis variantes. Las características se midieron con la máscara de referencia, para separar el efecto de la compresión del de la segmentación.

2.7. Análisis estadístico

Como el Dice y la mayoría de las características no tienen una distribución normal, se utilizaron pruebas no paramétricas, que comparan los valores ordenados de menor a mayor en lugar de sus medias. En todos los casos se consideró significativa una diferencia con un valor p menor que 0,05. Se utilizaron las siguientes pruebas:

- La prueba de Kruskal–Wallis compara los tres diagnósticos a la vez y evalúa si al menos uno tiende a presentar valores distintos de los otros.
- La prueba U de Mann–Whitney compara dos grupos independientes. Se utilizó para comparar el melanoma con las lesiones benignas (nevus y queratosis seborreica agrupados).
- La prueba de rangos con signo de Wilcoxon compara dos mediciones realizadas sobre las mismas imágenes, analizando la diferencia en cada imagen. Se utilizó para comparar el Dice de dos métodos de segmentación, y el Dice de cada variante de compresión con el de la imagen sin recomprimir.
- El coeficiente de correlación de Spearman (ρ) mide si dos variables aumentan o disminuyen juntas, entre -1 y 1. Se utilizó para relacionar cada característica con la resolución original de la imagen y para comparar los valores medidos con ambas máscaras.

Para medir cuánto distingue cada característica al melanoma de las lesiones benignas se utilizó el área bajo la curva ROC (AUC), que se obtiene directamente del estadístico U de Mann–Whitney:

$$\mathrm{AUC} = \frac{U}{n_1\, n_2} \tag{9}$$

donde n_1 y n_2 son la cantidad de melanomas y de lesiones benignas. El AUC es la probabilidad de que un melanoma elegido al azar tenga un valor mayor que una lesión benigna elegida al azar. Un AUC de 0,5 indica que la característica no distingue los grupos y un AUC de 1, que los separa perfectamente; un AUC menor que 0,5 indica que el melanoma tiende a tener valores menores.

Como se compararon 25 características a la vez, es esperable que alguna resulte significativa por azar. Para evitarlo, los valores p se corrigieron por comparaciones múltiples con el método de Benjamini–Hochberg, que los aumenta según la cantidad de pruebas realizadas. En el informe, el término p corregido se refiere a este valor.

Por último, como las imágenes provienen de distintos centros y el conjunto de datos no informa el equipo con el que se adquirió cada una, se utilizó la resolución original como aproximación del origen. Para evaluar su influencia, se calculó la correlación de Spearman entre cada característica y la resolución dentro de cada diagnóstico, y se repitió la comparación del melanoma de dos formas: solo con las imágenes de alta resolución (más de 2000 píxeles de lado mayor) y solo frente a los nevus.

3. Resultados

3.1. Caracterización

Las 2000 imágenes son JPEG en RGB, con 8 bits por canal e intensidades de 0 a 255, pero presentan 162 resoluciones distintas, con un lado mayor de entre 576 y 6748 píxeles. La resolución depende del diagnóstico: el 99,2 % de las queratosis seborreicas supera los 2000 píxeles de lado mayor, frente al 55,9 % de los melanomas y el 54,3 % de los nevus. En la muestra de evaluación, solo 1 de las 50 queratosis proviene de la fuente de baja resolución, frente a 24 melanomas y 19 nevus. Las intensidades medias se superponen ampliamente entre diagnósticos.

3.2. Preprocesamiento

3.2.1. Suavizado y contraste

Los filtros de 3×3 redujeron el gradiente medio entre un 23 y un 27 % (PSNR de 44,5 a 46,3 dB), y los de 5×5, entre un 39 y un 45 %, sin diferencias consistentes entre mediana y gaussiano. La ecualización global y CLAHE aumentaron el contraste visual, pero redujeron la separación lesión–fondo en los tres diagnósticos (en nevus, por ejemplo, de 1,92 a 1,70 con CLAHE y a 1,40 con ecualización global), porque también realzan la textura de la piel y los artefactos.

3.2.2. Canal de color

El canal S presentó la mayor separación lesión–fondo en los tres diagnósticos, con medianas de 1,88 en melanoma, 2,05 en nevus y 1,91 en queratosis, frente a 1,66, 1,85 y 1,20 en escala de grises, y fue el mejor canal en 103 de las 150 imágenes. En el canal S la lesión, más saturada, aparece clara, mientras que los bordes oscuros del campo del dermatoscopio, de baja saturación, no se confunden con ella (Figura 2).

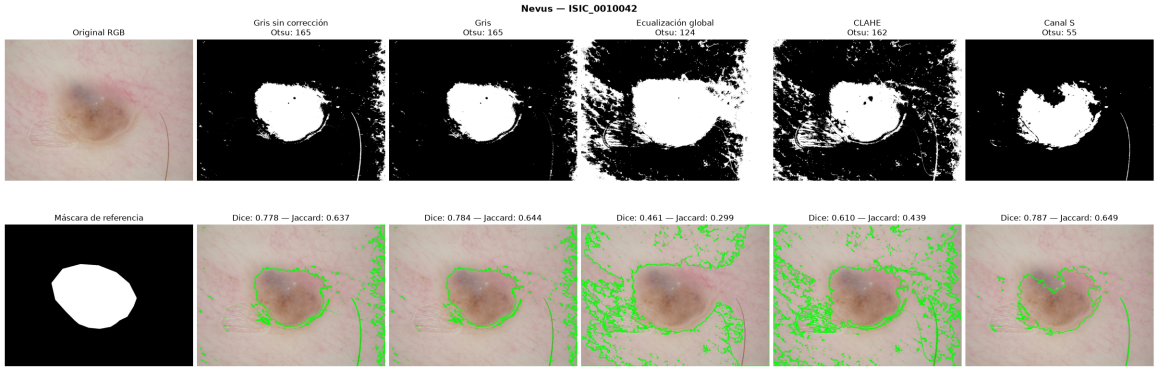


Figura 2: Otsu aplicado sobre cada entrada en un nevus. Arriba, la máscara obtenida; abajo, su contorno (verde), con el Dice y el Jaccard respecto de la referencia. En escala de grises se seleccionan los bordes oscuros del campo del dermatoscopio; la ecualización global y CLAHE agregan regiones de piel; en el canal S, los bordes del campo no se seleccionan.

3.2.3. Eliminación de pelos

Todas las combinaciones de elemento estructurante y umbral mejoraron el Dice respecto de no corregir, que fue de 0,509 en el conjunto de ajuste. Se eligieron un elemento de 9×9 y un umbral de 15 (Dice de 0,539), que corrigen el 4,1 % de la imagen. La combinación con mayor Dice (0,543) corregía el 12,3 % de la imagen y borraba estructuras de la propia lesión, por lo que se descartó. La Figura A.1 del Anexo muestra el resultado en dos imágenes con abundante vello.

3.2.4. Efecto sobre la segmentación

La Tabla A.1 del Anexo resume el efecto de estas decisiones sobre la segmentación con Otsu en la muestra de evaluación. La corrección de pelos y el uso del canal S mejoran la segmentación, mientras que la ecualización la empeora. El refinamiento, principalmente a través de la selección de componentes, mejora el Dice en 106 de las 150 imágenes y eleva el Dice mediano a 0,869 en melanoma, 0,870 en nevus y 0,773 en queratosis (Figura A.2 del Anexo). En nevus, el Dice medio baja levemente, de 0,676 a 0,657, porque en algunas imágenes la componente seleccionada no es la lesión.

3.3. Segmentación

En el conjunto de ajuste se eligieron un umbral fijo de 70, el percentil 90 para Canny y una tolerancia de 1,25 desvíos para el crecimiento de regiones. La Tabla 2 muestra los resultados de los cinco métodos en la muestra de evaluación; la distribución del Dice de cada método se presenta en la Figura A.3 del Anexo.

Tabla 2: Comparación de métodos de segmentación sobre el canal S, con el mismo refinamiento (150 imágenes). Fallas: imágenes con Dice menor que 0,5. En negrita, el mejor valor de cada columna en la que hay diferencias.

	Dice medio			Dice	Jaccard	
Método	Mel.	Nev.	QS	mediano	medio	Fallas
Umbral fijo	0,678	0,529	0,517	0,636	0,483	61
Otsu	0,814	0,657	0,600	0,839	0,605	34
Canny	0,628	0,427	0,345	0,459	0,374	83
Crecimiento de regiones	0,690	0,565	0,530	0,738	0,503	53
Chan–Vese	0,811	0,655	**0,672**	**0,850**	**0,622**	**32**

Chan–Vese y Otsu obtuvieron los mejores resultados, con desempeños similares: son prácticamente equivalentes en melanoma y nevus, mientras que en queratosis seborreica Chan–Vese mejora el Dice medio de 0,600 a 0,672. Al comparar ambos métodos imagen por imagen, Chan–Vese mejoró el Dice de Otsu en 50 imágenes y lo empeoró en 29, una diferencia significativa según la prueba de Wilcoxon ($p = 0{,}040$), aunque la diferencia mediana es prácticamente nula. Una explicación posible es que, en las queratosis, la saturación de la lesión y la de la piel no forman dos grupos bien separados en el histograma, que es lo que requiere Otsu, mientras que Chan–Vese tiene en cuenta la continuidad espacial de la región.

Los demás métodos tuvieron un desempeño inferior. El umbral fijo no se adapta a las diferencias de iluminación entre imágenes; el crecimiento de regiones se detiene en zonas internas de distinta saturación o se extiende a través de bordes graduales; y Canny genera bordes fragmentados en la lesión y bordes adicionales en la piel y los artefactos (Figura 3). Ningún método es el mejor en todas las imágenes: en el melanoma de la Figura 3, Chan–Vese se extiende hacia las manchas pigmentadas vecinas (Dice de 0,317), mientras que Otsu, gracias a la selección de componentes, obtiene 0,856.

Se eligió Chan–Vese para la extracción de características, por su mayor Dice medio y mediano, su menor cantidad de fallas y su mejor desempeño en queratosis seborreica. Como desventajas, es mucho más lento que Otsu (varios segundos por imagen, frente a milisegundos) y en 3 imágenes la máscara abarcó toda la imagen.

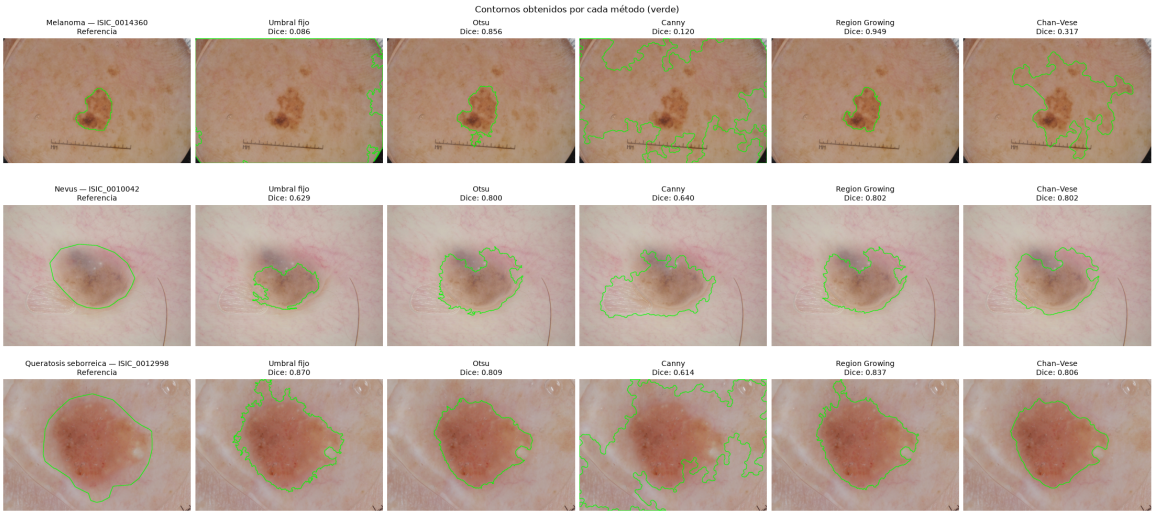


Figura 3: Contornos obtenidos por cada método (verde) en un melanoma, un nevus y una queratosis seborreica. La primera columna muestra la máscara de referencia.

3.4. Características

3.4.1. Diferencias entre diagnósticos

Con las máscaras de referencia, 17 de las 25 características difieren entre los tres diagnósticos (Kruskal–Wallis) y 14 difieren entre el melanoma y las lesiones benignas (Mann–Whitney), en ambos casos con p corregido menor que 0,05. Sin embargo, ninguna separa los grupos por sí sola: el AUC

máximo es de 0,72 y los rangos de valores se superponen ampliamente (Tabla 3 y Figura 4).

Las mayores diferencias corresponden a la dispersión del color (heterogeneidad en CIELAB y desvíos de G y B, con AUC cercanos a 0,70), a la textura, con mayor correlación y menor energía de la GLCM en el melanoma, y a la asimetría (AUC de 0,65). La circularidad, la convexidad y el contraste de la GLCM, en cambio, no difieren. El área relativa también difiere, pero depende del encuadre de cada imagen y no representa el tamaño real de la lesión. Algunas características son redundantes, como los parámetros de la GLCM a distancias de 1 y 3 píxeles ($|\rho| \geq 0{,}97$) y la heterogeneidad de color y el desvío de G ($\rho = 0{,}97$).

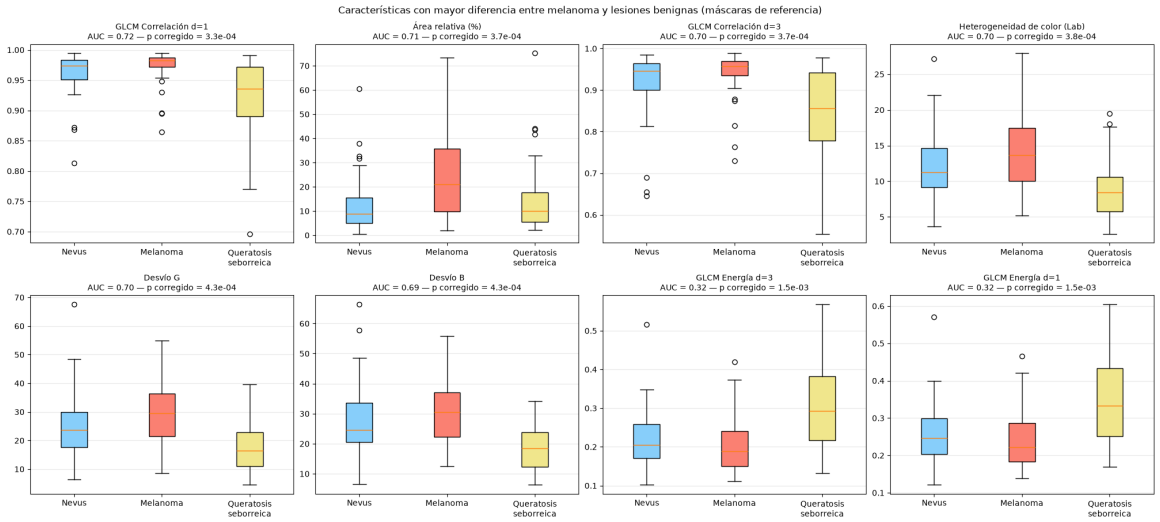


Figura 4: Las ocho características con mayor diferencia entre melanoma y lesiones benignas (máscaras de referencia). En cada título se indican el AUC del melanoma frente a las lesiones benignas y el p corregido.

Tabla 3: Características seleccionadas: medianas por diagnóstico con la máscara de referencia, AUC del melanoma en el análisis principal y en el análisis de sensibilidad, y efecto de la segmentación automática (Chan–Vese). En negrita, los AUC con p corregido menor que 0,05.

	Mediana (referencia)			AUC del melanoma (referencia)			Máscara automática	
Característica	Nev.	Mel.	QS	vs. benignas	vs. benignas (alta res.)	vs. nevus	ρ con referencia	AUC vs. benignas
Asimetría media	0,064	0,081	0,069	**0,652**	0,674	**0,698**	0,25	0,461
Solidez	0,957	0,939	0,950	**0,388**	0,429	0,379	0,07	0,540
Circularidad	0,668	0,682	0,621	0,502	0,543	0,452	−0,10	0,510
Área relativa (%)	8,9	21,1	10,0	**0,707**	0,625	**0,722**	0,51	0,612
Heterogeneidad de color	11,3	13,7	8,4	**0,701**	0,659	0,609	0,84	0,656
Desvío G	23,7	29,5	16,5	**0,696**	0,663	0,600	0,87	0,671
Contraste lesión–piel	0,137	0,128	0,045	**0,637**	0,568	0,567	0,79	0,675
GLCM correlación ($d = 1$)	0,974	0,982	0,936	**0,719**	**0,692**	0,627	0,88	0,692
GLCM energía ($d = 1$)	0,247	0,221	0,334	**0,324**	0,355	0,424	0,85	0,355
GLCM contraste ($d = 1$)	0,364	0,362	0,350	0,522	0,487	0,498	0,74	0,525

3.4.2. Origen de las imágenes

Dentro de un mismo diagnóstico, la dispersión del color y la textura se correlacionan con la resolución original en melanoma y nevus ($|\rho|$ entre 0,4 y 0,6, $p < 0{,}01$), mientras que la asimetría no depende de la resolución en ningún diagnóstico. Es decir, el equipo con el que se adquirió la imagen influye sobre las características de color y textura, pero no sobre la asimetría.

El análisis de sensibilidad (Tabla 3) confirma este resultado. La asimetría es la característica que distingue al melanoma de manera más consistente: su AUC es de 0,65 frente a las lesiones benignas, 0,67 en las imágenes de alta resolución y 0,70 frente a los nevus, con un p corregido de 0,008 en esta última comparación. En cambio, la dispersión del color y la textura dejan de distinguir al melanoma

cuando se lo compara solo con los nevus (AUC de 0,60 a 0,63, no significativo). En las imágenes de alta resolución, melanoma y nevus tienen casi la misma heterogeneidad de color (medianas de 10,3 y 10,2), frente a 8,3 en la queratosis. Por lo tanto, las diferencias de color y textura reflejan sobre todo a la queratosis seborreica, que no es una lesión melanocítica y cuyas imágenes provienen casi todas de la misma fuente.

3.4.3. Efecto de la segmentación

Para evaluar si el algoritmo puede reemplazar a las máscaras de los especialistas, se compararon los valores de cada característica medidos con la máscara automática de Chan–Vese y con la máscara de referencia (Figura 5).

Las características de color y textura dan valores muy similares con ambas máscaras, con una correlación de Spearman de entre 0,71 y 0,90, y distinguen al melanoma con un AUC similar. Esto se debe a que dependen del contenido de la lesión: aunque la máscara automática no coincida exactamente con el borde real, abarca casi la misma región, por lo que el color y la textura medidos casi no cambian.

Las características de forma, en cambio, dependen directamente del contorno, por lo que cualquier error en el borde modifica su valor. La asimetría medida con la máscara automática se parece poco a la de referencia ($\rho = 0{,}25$) y deja de distinguir al melanoma: su AUC pasa de 0,65 a 0,46, un valor cercano al azar. La solidez y la circularidad prácticamente no se correlacionan con los valores de referencia. Esto no implica necesariamente que el contorno automático sea menos preciso en todos los casos: las máscaras de referencia de ISIC tienen bordes suaves, que representan la forma general de la lesión pero no sus irregularidades finas, mientras que las automáticas siguen el borde con más detalle. Sin embargo, ese detalle incluye también variaciones producidas por la textura de la piel y por restos de pelos, y en las segmentaciones fallidas la máscara abarca manchas vecinas o queda fragmentada (puntos oscuros en la Figura 5). Como la asimetría de la regla ABCD evalúa la forma global de la lesión, para aprovecharla se necesita un contorno que represente correctamente esa forma, sin incorporar estas variaciones.

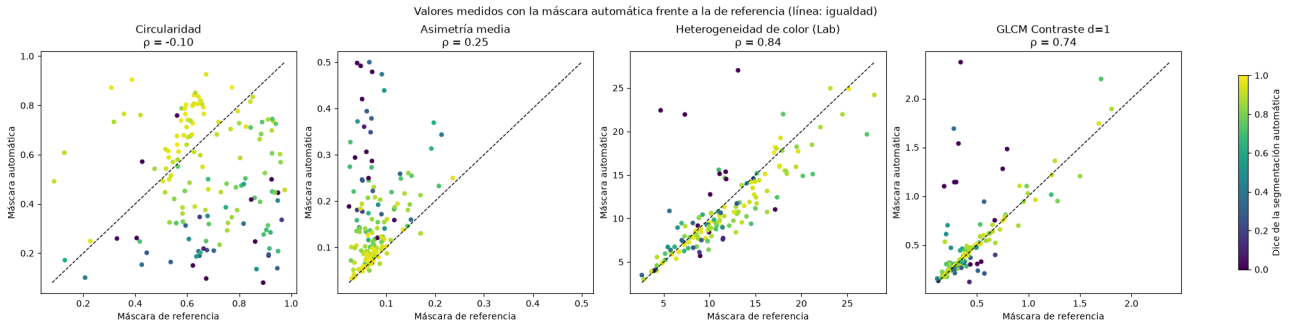


Figura 5: Valores obtenidos con la máscara automática (Chan–Vese) frente a los obtenidos con la máscara de referencia, coloreados por el Dice de la segmentación. Línea de trazos: igualdad. Se muestran 147 lesiones, porque en 3 imágenes la máscara automática abarcó toda la imagen y no quedó piel alrededor para calcular el contraste lesión–piel.

3.5. Compresión

La calidad JPEG de las imágenes originales es alta: su mediana es de 100 en las imágenes de alta resolución y de 95 en las de baja resolución. PNG reduce el tamaño de los archivos 2,6 veces y reconstruye la imagen exactamente (Tabla 4; Figura A.4 del Anexo).

Con JPEG, la segmentación no cambia significativamente hasta la calidad 25: al comparar cada variante con la imagen sin recomprimir mediante la prueba de Wilcoxon, se obtiene $p \geq 0{,}22$. Esto se debe a que la diferencia de saturación entre la lesión y la piel es una variación grande y gradual, que JPEG conserva. Con calidad 10, en cambio, los artefactos de bloque deforman el borde de la lesión y el Dice medio baja a 0,630 ($p < 0{,}001$). En el recorte ampliado de la Figura A.5 del Anexo, con calidad 75 no se observan diferencias con la original, mientras que con calidad 25 y 10 aparecen bloques de color uniforme de 16×16 píxeles, porque JPEG guarda los canales de color con la mitad de resolución que el brillo.

El color cambia menos del 2 % hasta la calidad 25. La textura es la más sensible: el contraste de la GLCM disminuye un 9 % con calidad 75 y un 21 % con calidad 10, porque JPEG elimina las variaciones finas entre píxeles vecinos. Como este efecto es similar en todos los diagnósticos, los AUC se mantienen; por ejemplo, el de la heterogeneidad de color es de 0,70 en todas las variantes.

Tabla 4: Efecto de la compresión (150 imágenes a la resolución de trabajo). Tasa: mediana de la tasa de compresión (Ecuación 8). Δ GLCM: cambio relativo mediano del contraste de la GLCM ($d = 1$) respecto de la imagen original.

Variante	Tasa	PSNR (dB)	SSIM	Dice medio	Δ GLCM
Original	1	—	1	0,690	—
PNG	2,6	∞	1	0,690	0 %
JPEG 95	13,1	46,5	0,991	0,694	1,0 %
JPEG 75	40,0	41,0	0,969	0,696	8,7 %
JPEG 50	66,1	38,4	0,951	0,693	14,2 %
JPEG 25	104,0	35,9	0,922	0,696	17,7 %
JPEG 10	150,7	31,6	0,860	0,630	21,7 %

4. Conclusiones

Se cumplió el objetivo general: se desarrolló un algoritmo que segmenta automáticamente las lesiones y extrae características cuantitativas, y se analizó si estas difieren entre diagnósticos y qué factores las afectan.

En cuanto al preprocesamiento, la elección del canal de color fue la decisión más influyente: el canal S separa la lesión del fondo mejor que la escala de grises y evita seleccionar los bordes oscuros del dermatoscopio. La mejora de contraste, en cambio, perjudica la segmentación, porque realza también la textura de la piel y los artefactos. La eliminación de pelos mediante black-hat y su reconstrucción por inpainting mejoró la segmentación.

Respecto de la segmentación, Chan–Vese y Otsu sobre el canal S, con refinamiento morfológico, alcanzan un Dice mediano de 0,85 y 0,84 y un Jaccard medio de 0,62 y 0,61, respectivamente. Estos valores son inferiores al Jaccard de 0,765 de la mejor propuesta del desafío ISIC 2017, basada en redes neuronales profundas [4, 5]. Sin embargo, esa propuesta se evaluó sobre otro conjunto de imágenes y requiere entrenamiento con miles de imágenes etiquetadas, mientras que el método desarrollado no requiere entrenamiento y cada una de sus etapas es interpretable. Cerca del 20 % de las imágenes presenta segmentaciones deficientes, principalmente cuando la región de mayor área no es la lesión o cuando la lesión queda fragmentada.

Al controlar el origen de las imágenes, la asimetría resulta la característica que distingue al melanoma de forma más robusta, en línea con el criterio A de la regla ABCD. Las diferencias de color y textura, en cambio, se deben sobre todo a la queratosis seborreica, y en parte pueden reflejar el equipo de adquisición más que la lesión. Ninguna característica es suficiente por sí sola: los AUC obtenidos, de 0,72 como máximo, son inferiores al 0,874 de los mejores clasificadores de ISIC 2017 [4], que combinan muchas características. Cabe aclarar que esta comparación es solo orientativa, ya que en este trabajo cada característica se evaluó por separado y no se construyó un clasificador.

En cuanto a la robustez del algoritmo, el color y la textura se mantienen con la segmentación automática, pero la forma se degrada, por lo que la precisión del contorno es la principal limitación del sistema. Además, la compresión JPEG con calidad 75 reduce el tamaño de las imágenes unas 40 veces sin afectar la segmentación ni el color; para analizar la textura, conviene una calidad de 95 o superior, o una compresión sin pérdida.

Entre las limitaciones, la muestra es de 150 imágenes, no se conocen la escala física ni el equipo de adquisición de cada imagen, y casi todas las queratosis seborreicas provienen de una misma fuente. Como trabajo futuro, se propone ampliar el análisis a las 2000 imágenes, normalizar el color entre equipos de adquisición, detectar automáticamente las segmentaciones fallidas para reemplazarlas por otro método, combinar las características más robustas en un clasificador y comparar los resultados con métodos de segmentación basados en aprendizaje profundo.

Referencias

[1] Elvira Moscarella, Gabriella Brancaccio, Giulia Briatico, Andrea Ronchi, Simonetta Piana, and Giuseppe Argenziano. Differential diagnosis and management on seborrheic keratosis in elderly patients. *Clinical, Cosmetic and Investigational Dermatology*, 14:395–406, 2021. doi: 10.2147/CCID.S267246.

[2] Wilhelm Stolz, A. Riemann, A. B. Cognetta, L. Pillet, W. Abmayr, D. Hölzel, P. Bilek, F. Nachbar, M. Landthaler, and O. Braun-Falco. ABCD rule of dermatoscopy: a new practical method for early recognition of malignant melanoma. *European Journal of Dermatology*, 4:521–527, 1994.

[3] Catarina Barata, M. Emre Celebi, and Jorge S. Marques. A survey of feature extraction in dermoscopy image analysis of skin cancer. *IEEE Journal of Biomedical and Health Informatics*, 23(3):1096–1109, 2019.

[4] Noel C. F. Codella, David Gutman, M. Emre Celebi, Brian Helba, Michael A. Marchetti, Stephen W. Dusza, Aadi Kalloo, Konstantinos Liopyris, Nabin Mishra, Harald Kittler, and Allan Halpern. Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (ISBI), hosted by the international skin imaging collaboration (ISIC). In *2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018)*, pages 168–172, 2018.

[5] Yading Yuan, Ming Chao, and Yeh-Chi Lo. Automatic skin lesion segmentation with fully convolutional-deconvolutional networks, 2017. arXiv:1703.05165.

Anexo

Tabla A.1: Dice medio de Otsu según la entrada y el refinamiento (150 imágenes). Mel.: melanoma; Nev.: nevus; QS: queratosis seborreica. En negrita, el mayor valor de cada columna.

Entrada	Mel.	Nev.	QS
Gris sin corrección de pelos	0,584	0,514	0,403
Gris corregido	0,611	0,533	0,431
+ ecualización global	0,497	0,326	0,336
+ CLAHE	0,548	0,487	0,386
Canal S corregido	0,729	**0,676**	0,553
+ refinamiento	**0,814**	0,657	**0,600**

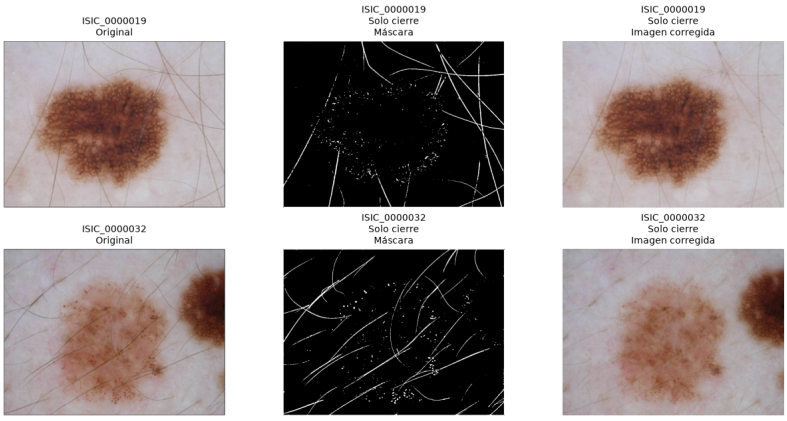


Figura A.1: Eliminación de pelos en dos imágenes con abundante vello: imagen original, máscara de pelos (black-hat de 9×9, umbral 15 y cierre) e imagen reconstruida mediante inpainting.

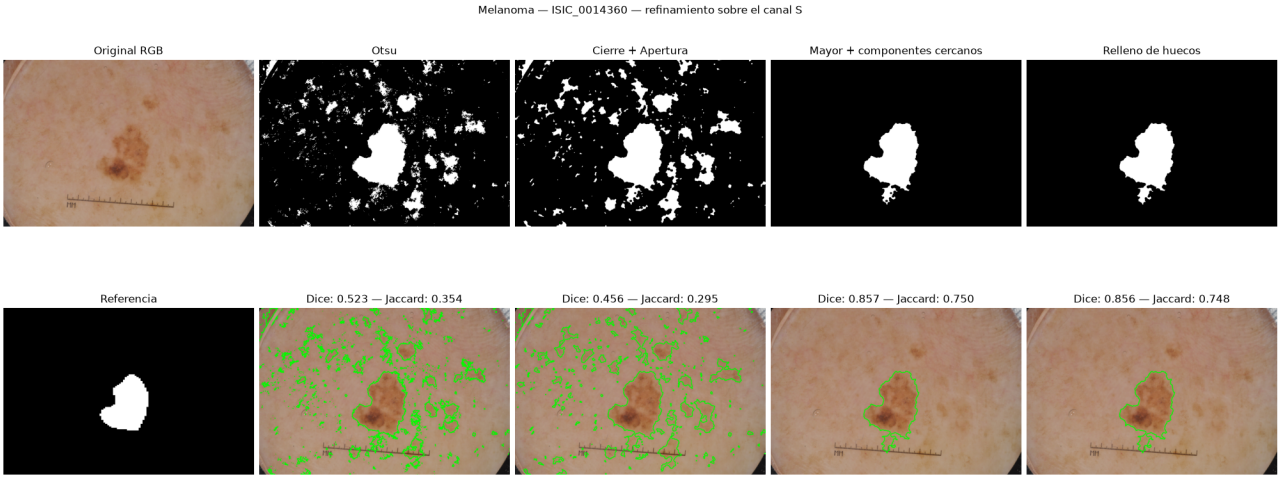


Figura A.2: Etapas del refinamiento sobre la máscara de Otsu en el canal S, en un melanoma. La selección de la componente principal y de sus vecinas elimina las manchas pigmentadas externas, y el Dice pasa de 0,523 a 0,856.

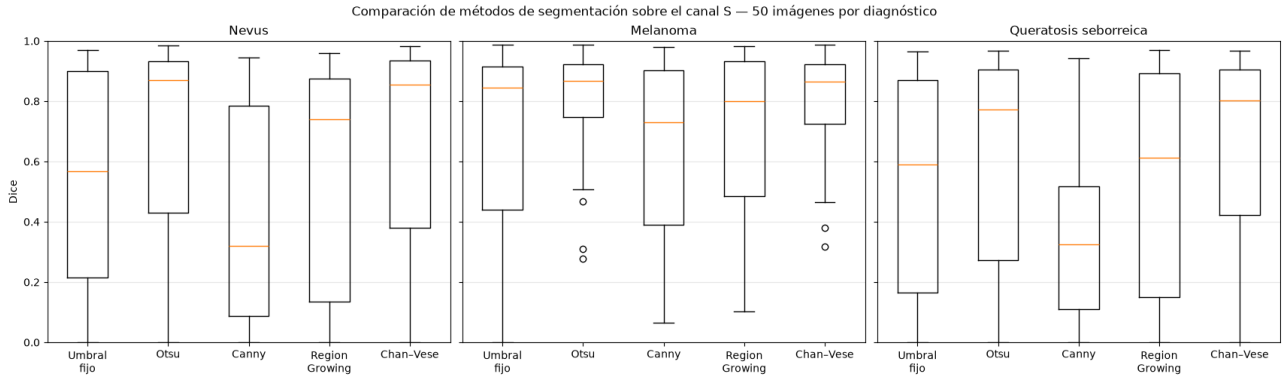


Figura A.3: Distribución del Dice de cada método por diagnóstico (50 imágenes por diagnóstico).

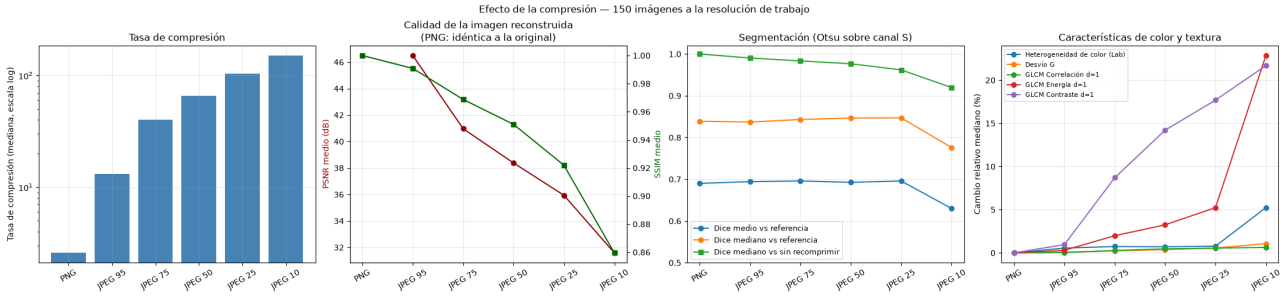


Figura A.4: Efecto de la compresión según la variante: tasa de compresión, calidad de la imagen reconstruida (en PNG la PSNR es infinita y no se grafica), Dice de la segmentación con Otsu y cambio relativo mediano de las características.

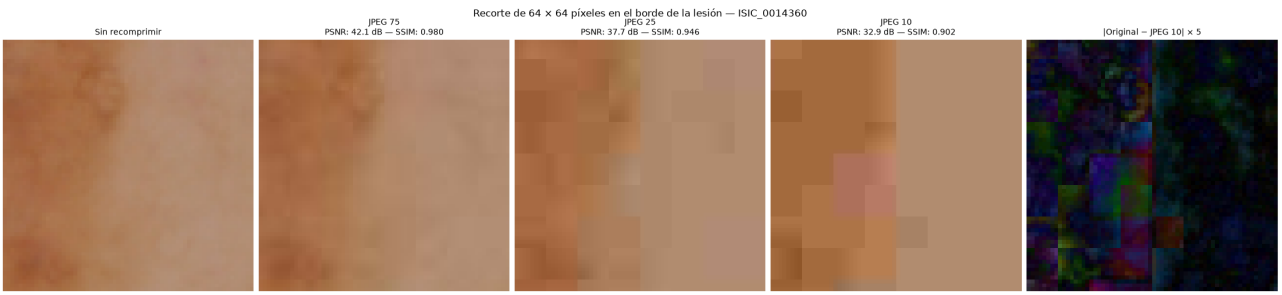


Figura A.5: Recorte de 64×64 píxeles en el borde de una lesión con distintas calidades JPEG. A la derecha, la diferencia absoluta entre la imagen original y JPEG 10, amplificada cinco veces.